#### COMP130014.02 编译

# 第四讲: 自顶向下解析

徐辉 xuh@fudan.edu.cn



### 自顶向下解析

- ❖一、问题定义
- ❖二、Earley算法
- ❖三、LL(1)文法和解析

# 一、问题定义

#### 自顶向下解析

- 已知一套CFG语法规则和待解析的句子
- 应用语法规则(从左至右)逐步展开每个非终结符
- 从CFG的开始符号应用规则逐步展开其中的非终结符
  - 如果能得到目标句子=>解析成功
  - 如果不能得到目标句子=>解析失败
- 如无二义性问题,则语法解析树唯一

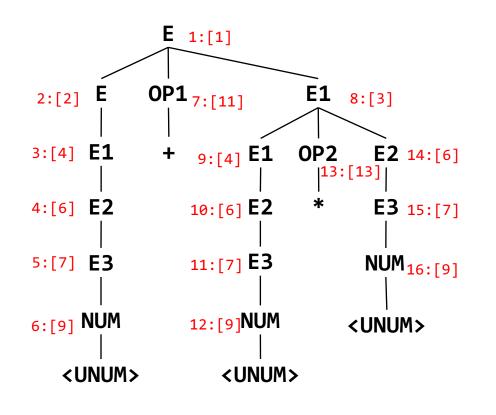
#### 自顶向下解析示例

#### 语法规则:

```
[1] E \rightarrow E OP1 E1
[2] E \rightarrow E1
[3] E1 \rightarrow E1 OP2 E2
[4] E1 \rightarrow E2
[5] E2 \rightarrow E3 OP3 E2
[6] E2 \rightarrow E3
[7] E3 \rightarrow NUM
[8] E3 \rightarrow '(' E ')'
[9] NUM \rightarrow <UNUM>
[10] NUM → '-' <UNUM>
[11] OP1 \rightarrow '+'
[12] OP1 \rightarrow '-'
[13] OP2 \rightarrow '*'
[14] OP2 \rightarrow '/'
[15] OP3 \rightarrow '^'
```

解析对象: 1+2\*3

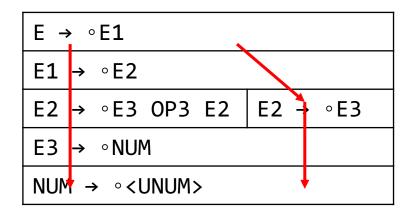
标签流: <UNUM><ADD><UNUM><MUL><UNUM>

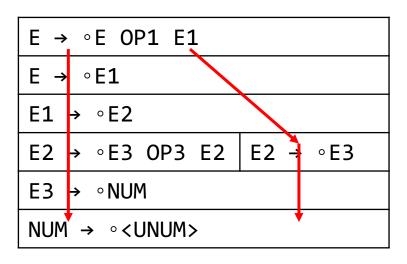


语法解析树

#### 如何自动生成语法推导树?

- 如何判断当前应采用哪条规则展开? 暴力搜索?
- 预测解析: 找出可以生成目标终结符的规则
- 可能存在多种展开方式以及递归问题





# 二、Earley算法

#### 解析状态分析

- 句柄: 语法规则中已解析的字符
- 规范项(canonical item): 规则 $X \to \gamma$ 对应 $|\gamma| + 1$ 种句柄状态

句柄分析

```
[1] E \rightarrow E OP1 E1
[2] E \rightarrow E1
[3] E1 \rightarrow E1 OP2 E2
[4] E1 \rightarrow E2
[5] E2 \rightarrow E3 OP3 E2
[6] E2 \rightarrow E3
[7] E3 → NUM
[8] E3 \rightarrow '(' E ')'
[9] NUM \rightarrow \langle UNUM \rangle
[10] NUM \rightarrow '-' <UNUM>
[11] OP1 \rightarrow '+'
[12] OP1 → '-'
[13] OP2 \rightarrow '*'
[14] OP2 \rightarrow '/'
[15] OP3 → '^'
```

```
[1] E \rightarrow \circ E OP1 E1
[1] E \rightarrow E \circ OP1 E1
      E \rightarrow E OP1 \circ E1
[1] E \rightarrow E OP1 E1 \circ
      E \rightarrow \circ E1
[2] E \rightarrow E1 \circ
[3] E1 \rightarrow \circ E1 OP2 E2
[3] E1 \rightarrow E1 \circ OP2 E2
[3] E1 \rightarrow E1 OP2 \circ E2
[3] E1 \rightarrow E1 OP2 E2 \circ
```

# Earley算法: 通用自顶向下语法分析算法

- 支持递归
- 三种基本操作:
  - **预测**:对于每个规范项 $X \to \alpha \circ Y\beta$ ,根据语法规则展开 $Y \to \circ \gamma$
  - 扫描: 如果下一个终结符是a,且存在规范项  $X \to \alpha \circ a\beta$ ,则将其更新为 $X \to \alpha a \circ \beta$
  - 完成/更新:  $Y \to \gamma \circ$  即完成了对Y的分析, 更新  $X \to \alpha \circ Y \beta$ 为  $X \to \alpha Y \circ \beta$

# 解析过程演示

```
[1] E \rightarrow E OP1 E1
[2] E \rightarrow E1
[3] E1 \rightarrow E1 OP2 E2
\lceil 4 \rceil E1 \rightarrow E2
[5] E2 \rightarrow E3 OP3 E2
[6] E2 \rightarrow E3
[7] E3 \rightarrow NUM
[8] E3 \rightarrow '(' E ')'
[9] NUM \rightarrow \langle UNUM \rangle
[10] NUM → '-' <UNUM>
[11] OP1 \rightarrow '+'
[12] OP1 \rightarrow '-'
[13] OP2 \rightarrow '*'
[14] OP2 \rightarrow '/'
[15] OP3 → '^'
```

序号	操作	规范项	起源					
s[0]	s[0] = • <unum> '+' <unum> '*' <unum></unum></unum></unum>							
1	起始状态	E → ° E OP1 E1	s[0]					
2	起始状态	E → ° E1	s[0]					
3	预测[2]	E1 → ° E1 OP2 E2	s[0]					
4	预测[2]	E1 → ° E2	s[0]					
5	预测[4]	E2 → ∘ E3 OP3 E2	s[0]					
6	预测[4]	E2 → ° E3	s[0]					
7	预测[5]	E3 → ∘ NUM	s[0]					
8	预测[5]	E3 → ° '(' E ')'	s[0]					
9	预测[7]	NUM → ° <unum></unum>	s[0]					
10	预测[7]	NUM → ° '-' <unum></unum>	s[0]					
s[1]	= <unum> ° '+' <unum> '*</unum></unum>	' <unum></unum>						
1	基于s[0][9]扫描	NUM → <unum> ∘</unum>	s[0]					

序号	操作	规范项	起源
s[0] = °	<unum> '+' <unum> '*' <unum></unum></unum></unum>		
1	起始状态	E → ° E OP1 E1	s[0]
2	起始状态	E → ° E1	s[0]
3	预测[2]	E1 → ° E1 OP2 E2	s[0]
4	预测[2]	E1 → ° E2	s[0]
5	预测[4]	E2 → ° E3 OP3 E2	s[0]
6	预测[4]	E2 → ° E3	s[0]
7	预测[5]	E3 → ° NUM	s[0]
8	预测[5]	E3 → ° '(' E ')'	s[0]
9	预测[7]	NUM → ° <unum></unum>	s[0]
10	预测[7]	NUM → ° '-' <unum></unum>	s[0]
s[1] = <	JNUM> ° '+' <unum> '*' <unum></unum></unum>		
1	扫描s[0][9]	NUM → <unum> °</unum>	s[0]
2	基于[1]更新s[0][7]	E3 → NUM ∘	s[0]
3	基于[2]更新s[0][5]	E2 → E3 ∘ OP3 E2	s[0]
4	基于[2]更新s[0][6]	E2 → E3 ∘	s[0]
5	基于[4]更新s[0][4]	E1 → E2 °	s[0]
6	基于[5]更新s[0][2]	E → E1 °	s[0]
7	基于[5]更新s[0][3]	E1 → E1 ∘ OP2 E2	s[0]
8	基于[6]更新s[0][1]	E → E ∘ OP1 E1	s[0] <sub>11</sub>

序号	操作	规范项	起源				
s[1] = <	s[1] = <unum> ° '+' <unum> '*' <unum></unum></unum></unum>						
1	扫描s[0][9]	NUM → <unum> °</unum>	s[0]				
2	基于[1]更新s[0][7]	E3 → NUM ∘	s[0]				
3	基于[2]更新s[0][5]	E2 → E3 ∘ OP3 E2	s[0]				
4	基于[2]更新s[0][6]	E2 → E3 ∘	s[0]				
5	基于[4]更新s[0][4]	E1 → E2 °	s[0]				
6	基于[5]更新s[0][2]	E → E1 °	s[0]				
7	基于[5]更新s[0][3]	E1 → E1 ∘ OP2 E2	s[0]				
8	基于[6]更新s[0][1]	E → E ∘ OP1 E1	s[0]				
9	预测[3]	OP3 → ° '^'	s[1]				
10	预测[7]	OP2 → ° '*'	s[1]				
11	预测[7]	OP2 → ° '/'	s[1]				
12	预测[8]	OP1 → ° '+'	s[1]				
13	预测[8]	OP1 → ° '-'	s[1]				
s[2] = <unum> '+' • <unum> '*' <unum></unum></unum></unum>							
1	扫描s[1][12]	OP1 → '+' °	s[1]				
2							
3							

序号	操作	规范项	起源				
s[2] = <unum> '+' • <unum> '*' <unum></unum></unum></unum>							
1	扫描s[1][12]	OP1 → '+' °	s[1]				
2	基于[1]更新s[1][8]	E → E OP1 ∘ E1	s[0]				
3	预测[2]	E1 → ° E1 OP2 E2	s[2]				
4	预测[2]	E1 → ° E2	s[2]				
5	预测[4]	E2 → ° E3 OP3 E2	s[2]				
6	预测[4]	E2 → ° E3	s[2]				
7	预测[5]	E3 → ° NUM	s[2]				
8	预测[5]	E3 → ° '(' E ')'	s[2]				
9	预测[7]	NUM → ° <unum></unum>	s[2]				
10	预测[7]	NUM → ° '-' <unum></unum>	s[2]				
s[3] = <	UNUM> '+' <unum> ° '*' <unum></unum></unum>						
1	扫描s[2][9]	NUM → <unum> °</unum>	s[2]				
2	基于[1]更新s[2][7]	E3 → NUM ∘	s[2]				
3	基于[2]更新s[2][5]	E2 → E3 ∘ OP3 E2	s[2]				
4	基于[2]更新s[2][6]	E2 → E3 °	s[2]				
5	基于[4]更新s[2][4]	E1 → E2 °	s[2]				
6	基于[5]更新s[2][2]	E → E OP1 E1 °	s[0]				
7	基于[5]更新s[2][3]	E1 → E1 ∘ OP2 E2	s[2]				
8			13				

序号	操作	规范项	起源					
s[3] = <	s[3] = <unum> '+' <unum> ° '*' <unum></unum></unum></unum>							
1	扫描s[2][9]	NUM → <unum> °</unum>	s[2]					
2	基于[1]更新s[2][7]	E3 → NUM∘	s[2]					
3	基于[2]更新s[2][5]	E2 → E3 ∘ OP3 E2	s[2]					
4	基于[2]更新s[2][6]	E2 → E3 °	s[2]					
5	基于[4]更新s[2][4]	E1 → E2 °	s[2]					
6	基于[5]更新s[2][2]	E → E OP1 E1 °	s[0]					
7	基于[5]更新s[2][3]	E1 → E1 ∘ OP2 E2	s[2]					
8	预测[3]	OP3 → ° '^'	s[3]					
9	预测[7]	OP2 → ° '*'	s[3]					
10	预测[7]	OP2 → ° '/'	s[3]					
s[4] = <	JNUM> '+' <unum> '*' · <unum></unum></unum>							
1	扫描s[3][9]	OP2 → ° '*'	s[3]					
2	基于[1]更新s[3][7]	E1 → E1 OP2 ∘ E2	s[2]					
3	预测[2]	E2 → ∘ E3 OP3 E2	s[4]					
4	预测[2]	E2 → ° E3	s[4]					
5	预测[3]	E3 → ° NUM	s[4]					
6	预测[3]	E3 → ° '(' E ')'	s[4]					
7	预测[5]	NUM → ° <unum></unum>	s[4]					
8	预测[5]	NUM → ° '-' <unum></unum>	s[4] <sub>14</sub>					

序号	操作	规范项	起源
s[5] = <l< th=""><th>JNUM&gt; '+' <unum> '*' <unum> °</unum></unum></th><th></th><th></th></l<>	JNUM> '+' <unum> '*' <unum> °</unum></unum>		
1	扫描s[4][7]	NUM → <unum> °</unum>	s[4]
2	基于[1]更新s[4][5]	E3 → NUM ∘	s[4]
3	基于[2]更新s[4][3]	E2 → E3 ∘ OP3 E2	s[4]
4	基于[2]更新s[4][4]	E2 → E3 ∘	s[4]
5	基于[4]更新s[4][2]	E1 → E1 OP2 E2 ∘	s[2]
6	基于[5]更新s[2][2]	E → E OP1 E1 °	s[0]

# 练习

- 使用Earley算法解析:
  - 1\*(2+-3)

### Earley算法复杂度分析

- 1) O(句子长度 \* 规则个数 \* 规则长度)
- 2) O(句子长度2 \* 规则个数 \* 规则长度)
- 3) 其它

# 三、LL(1)文法和解析

#### 通过限制文法复杂度提升解析效率

- LL(1)文法的基本要求:
  - 无左递归
  - 无回溯
- LL(1)文法: Left-to-Right, Leftmost, 前瞻一个字符无回溯
- LL(k)文法: Left-to-Right, Leftmost, 前瞻k个字符无回溯



### 左递归问题

- 一条规则中右侧的第一个符号与左侧符号相同
- 可能导致搜索算法无限递归,不终止

```
[1] E \rightarrow E OP1 E1
[2] E \rightarrow E1
[3] E1 → E1 OP2 E2
[4] E1 \rightarrow E2
[5] E2 \rightarrow E3 OP3 E2
[6] E2 \rightarrow E3
[7] E3 \rightarrow NUM
[8] E3 \rightarrow '(' E ')'
[9] NUM \rightarrow \langle UNUM \rangle
[10] NUM → '-' <UNUM>
[11] OP1 \rightarrow '+'
[12] OP1 \rightarrow '-'
[13] OP2 → '*'
[14] OP2 \rightarrow '/'
[15] OP3 → '^'
```

#### 消除左递归

- 改写语法规则,使新旧规则等价:
  - 1) 引入新的非终结符E',使其可以为 $\epsilon$
  - 2) 将递归规则之外的产生式右侧置于E'之前
  - 3) 为E'构造产生式,使新旧规则等价

$$\begin{array}{c|c}
E \to E & \alpha \\
E' \to \alpha & E' \\
E' \to \epsilon
\end{array}$$

$$\begin{array}{c|c}
E \to E & \alpha \\
E \to \beta & E' \\
E \to \beta & E' \\
E \to \gamma & E' \\
E' \to \alpha & E'
\end{array}$$

$$\begin{array}{c|c}
F \cap B & \alpha \\
F \cap B \cap B &$$

#### 应用

```
[1] E \rightarrow E OP1 E1
[2] E \rightarrow E1
                                         消除左递归
[3] E1 \rightarrow E1 OP2 E2
[4] E1 \rightarrow E2
[5] E2 \rightarrow E3 OP3 E2
[6] E2 \rightarrow E3
[7] E3 \rightarrow NUM
[8] E3 \rightarrow '(' E ')'
[9] NUM \rightarrow \langle UNUM \rangle
[10] NUM \rightarrow '-' <UNUM>
[11] OP1 \rightarrow '+'
[12] OP1 \rightarrow '-'
[13] OP2 \rightarrow '*'
[14] OP2 \rightarrow '/'
[15] OP3 \rightarrow '^'
```

```
[1] E \rightarrow E1 E'
[2] E' → OP1 E1 E'
[3] E' \rightarrow \epsilon
[4] E1 → E2 E1'
[5] E1' → OP2 E2 E1'
[6] E1' \rightarrow \epsilon
[7] E2 \rightarrow E3 OP3 E2
[8] E2 \rightarrow E3
[9] E3 \rightarrow NUM
[10] E3 \rightarrow '(' E ')'
[11] NUM \rightarrow <UNUM>
[12] NUM \rightarrow '-' <UNUM>
[13] OP1 \rightarrow '+'
[14] OP1 \rightarrow '-'
[15] OP2 \rightarrow '*'
[16] OP2 \rightarrow '/'
[17] OP3 \rightarrow '^'
```

# 注意间接左递归问题

$$E \to \alpha$$

$$\alpha \to \beta +$$

$$\beta \to E$$

$$E \to E +$$

#### 无回溯语法

- 任意非终结符的任意两个产生式生成的首个终结符均不同
- 前瞻一个终结符总能选择正确的规则
- 消除语法规则选择时的不确定性, 避免回溯

[1] 
$$S \to \alpha \to \cdots \to a\gamma$$
  
[2]  $S \to \beta \to \cdots \to b\delta$ 

#### 消除回溯:提取左因子

- 改写语法规则, 使新旧规则等价:
  - 对一组生成式提取共同前缀,置于新非终结符E'之前
  - 为E'编写生成式规则,使新旧规则等价

$$E \to \alpha \beta_1 |\alpha \beta_2| \dots |\alpha \beta_n |\gamma_1| \dots |\gamma_j| \qquad \qquad \qquad E \to \alpha E' |\gamma_1| \dots |\gamma_j| \\ E' \to \beta_1 |\beta_2| \dots |\beta_n|$$

#### 应用

```
[1] E \rightarrow E1 E'
[2] E' → OP1 E1 E'
[3] E' \rightarrow \epsilon
[4] E1 \rightarrow E2 E1'
[5] E1' → OP2 E2 E1'
[6] E1' \rightarrow \epsilon
[7] E2 \rightarrow E3 OP3 E2
[8] E2 \rightarrow E3
[9] E3 \rightarrow NUM
[10] E3 \rightarrow '(' E ')'
[11] NUM \rightarrow <UNUM>
[12] NUM \rightarrow '-' <UNUM>
[13] OP1 \rightarrow '+'
[14] OP1 \rightarrow '-'
[15] OP2 \rightarrow '*'
[16] OP2 \rightarrow '/'
[17] OP3 \rightarrow '^'
```

消除回溯语法

```
[1] E \rightarrow E1 E'
[2] E' \rightarrow OP1 E1 E'
[3] E' \rightarrow \epsilon
[4] E1 \rightarrow E2 E1'
[5] E1' \rightarrow OP2 E2 E1'
[6] E1' \rightarrow \epsilon
[7] E2 \rightarrow E3 E2'
[8] E2' → OP3 E2
[9] E2' \rightarrow \epsilon
[10] E3 \rightarrow NUM
[11] E3 \rightarrow '(' E ')'
[12] NUM \rightarrow \langle UNUM \rangle
[13] NUM \rightarrow '-' <UNUM>
[14] OP1 \rightarrow '+'
[15] OP1 \rightarrow '-'
[16] OP2 \rightarrow '*'
[17] OP2 \rightarrow '/'
[18] OP3 \rightarrow '^'
```

# First集合计算

- 对于生成式 $A \rightarrow \beta_1 \beta_2 ... \beta_n$  来说:
  - 如果  $\epsilon \notin First(\beta_1)$ ,则 $First(A) = First(\beta_1)$
  - 如果  $\epsilon \in First(\beta_1)$ & ... & $\epsilon \in First(\beta_i)$ , 则 $First(A) = First(\beta_1) \cup ... \cup First(\beta_{i+1})$

```
[1] E → E1 E'
[2] E' \rightarrow OP1 E1 E'
[3] E' \rightarrow \epsilon
[4] E1 → E2 E1
[5] E1' → OP2 E2 E1'
[6] E1' \rightarrow \epsilon
[7] E2 → E3 E2'
[8] E2' → OP3 E2
[9] E2' \rightarrow \epsilon
[10] E3 → NUM
[11] E3 \rightarrow '(' E ')'
[12] NUM → <UNUM>
[13] NUM → '-' <UNUM>
[14] OP1 → '+'
[15] OP1 → '-'
[16] OP2 → '*'
[17] OP2 → '/'
[18] OP3 → '^'
```

	<unum></unum>	'+'	'-'	'*'	'/'	'^'	'('	')'	€
E	[1]		[1]				[1]		
E'		[2]	[2]						[3]
E1	[4]		[4]				[4]		
E1'				[5]	[5]				[6]
E2	[7]		[7]				[7]		
E2'						[8]			[9]
E3	[10]		[10]				[11]		
NUM	[12]		[13]						
OP1		[14]	[15]						
OP2				[16]	[17]				
0P3						[18]			

#### Follow集合计算

• 如果存在规则 $A \rightarrow \epsilon$ ,选择规则时需要考虑A之后紧跟的字符

$$First^{+}(A \to \beta) = \begin{cases} First(\beta), & if \epsilon \notin First(\beta) \\ First(\beta) \cup Follow(A), & otherwise \end{cases}$$

```
[1] E → E1 E
[2] E' → OP1 E1 E'
[3] E' \rightarrow \epsilon
[4] E1 → E2 E1
[5] E1' → OP2 E2 E1'
[6] E1' \rightarrow \epsilon
[7] E2 → E3 E2'
[8] E2' \rightarrow OP3 E2
[9] E2' \rightarrow \epsilon
[10] E3 → NUM
[11] E3 \rightarrow '(' E ')'
[12] NUM \rightarrow \langle UNUM \rangle
[13] NUM → '-' <UNUM>
[14] OP1 → '+'
[15] OP1 → '-'
[16] OP2 \rightarrow '*'
[17] OP2 \rightarrow '/'
[18] OP3 → '^'
```

	<unum></unum>	'+'	'-'	'*'	'/'	'^'	'('	')'	ε	
E	[1]		[1]				[1]			
E'		[2]	[2]					[3]	[3]	
E1	[4]		[4]		$\lceil Fol$	low(E')	) = Followskip	low(E)		
E1'		[6]	[6]	[5]	[5]			[6]	[6]	
E2	Follo	w(E1')	= Foll	ow(E1	) = Fir	$rst^+(E')$	[7]			
E2'		[9]	[9]	[9]	[9]	[8]		[9]	[9]	
E3	$Follow(E2') = Follow(E2) = First^{+}(E1')$									
NUM	[12]		[13]							
OP1		[14]	[15]							
OP2				[16]	[17]					
OP3						[18]				

### 基于First+集合得到解析表

- 解析表每一个单元格最多只有一条可选规则
- 无回溯语法特性:

$$\forall 1 \leq i, j \leq n, First^+(A \rightarrow \beta_i) \cap First^+(A \rightarrow \beta_j) = \emptyset$$

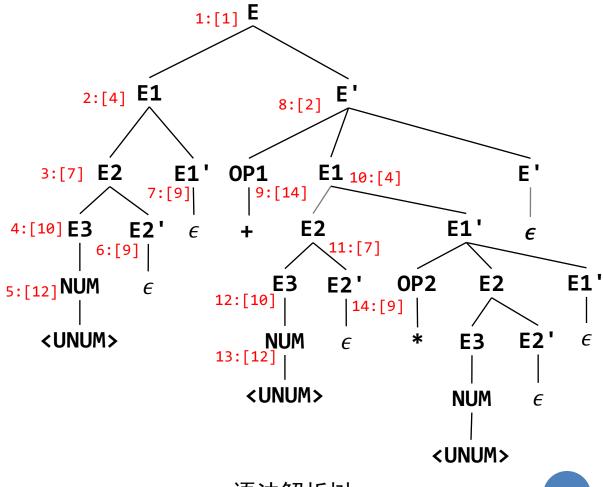
	<unum></unum>	'+'	'-'	'*'	'/'	'^'	'('	')'
E	[1]		[1]				[1]	
E'		[2]	[2]					[3]
E1	[4]		[4]				[4]	
E1'		[6]	[6]	[5]	[5]		[6]	
E2	[7]		[7]				[7]	
E2'		[9]	[9]	[9]	[9]	[8]	[9]	
E3	[10]		[10]				[11]	
NUM	[12]		[13]					
OP1		[14]	[15]					
OP2				[16]	[17]			
OP3						[18]		

# LL(1)解析表应用示例

```
[1] E \rightarrow E1 E'
     E' → OP1 E1 E'
    E' \rightarrow \epsilon
     E1 → E2 E1'
     E1' → OP2 E2 E1'
    E1' \rightarrow \epsilon
     E2 → E3 E2'
    E2' → OP3 E2
[9] E2' \rightarrow \epsilon
[10] E3 \rightarrow NUM
[11] E3 \rightarrow '(' E ')'
      NUM → <UNUM>
      NUM → '-' <UNUM>
      OP1 → '+'
      OP1 →
[16]
       OP2 →
      OP2 → '/'
[18] OP3 \rightarrow '^'
```

解析对象: 1+2\*3

标签流: <UNUM><ADD><UNUM><MUL><UNUM>



#### LL(1)算法复杂度分析

- 1) O(句子长度 \* 规则个数)
- 2) O(句子长度 \* 解析表行数)
- 3) 其它

#### 练习

• 将正则表达式CFG改写为LL(1)语法并写出解析表

```
[1] REGEX → REGEX '|' CONCAT

[2] REGEX → CONCAT

[3] CONCAT → CONCAT CLOSURE

[4] CONCAT → CLOSURE

[5] CLOSURE → CLOSURE '*'

[6] CLOSURE → ITEM

[7] ITEM → '(' REGEX ')'

[8] ITEM → <CHAR>
```